

DEVHOT | 研发前沿洞察

每日简报 · 2026-07-23

【今日热点词】

请求级模型路由

方法级授权

在线 A/B 评测

凭据一致性

Workspace Trust

今日主线

软件开发领域

今天的软件开发 Agent 变化集中在“决策控制面”上：Cursor 把每次请求交给可评估、可治理的模型路由器，Claude Code 把更多评审与 Forked Skill 移入后台执行并重划 Workspace Trust 与自动授权边界，Codex 则让持久睡眠线程能够被排队消息确定性唤醒。这些机制分别处理模型选择、执行权限和异步恢复，但共同要求 Harness 将隐含默认转化为可观测、可测试、可回退的运行时状态。厂商流量结果、分类器安全性和跨故障恢复仍需在独立环境中验证。

持续集成交付领域

今天的变化集中在 Agent 控制面的“语义正确性”：kagent 按 JSON-RPC 方法而非 HTTP 动词实施只读权限，OpenSRE 以统一 setup flow 消除多入口凭据漂移，gh-aw 则把失败掩盖、供应链固定和零轮驱动故障纳入可检查的运行契约。三者共同表明，交付与运维 Agent 的可靠性越来越依赖协议方法、配置存储、插桩和退出状态这些确定性边界，而不只是模型能否给出正确结论。

洞察速览 · 6 条

01 · 软件开发领域

Cursor 用请求级分类与生产反馈在模型质量和成本之间动态路由

Cursor 发布 Cursor Router，在每次请求执行前按 Query、Context、Task Complexity 与 Domain 分类，并在团队允许的模型池中选择执行模型。该机制把 Coding Agent 的模型选择从会话级人工偏好转为可在线评估的请求级控制面，使质量、缓存成本和组织策略能够在同一次路由决策中权衡。

[查看洞察](#) · [阅读原文](#)

02 · 软件开发领域

Claude Code 用后台执行与目录级信任重划评审和工具授权边界

Claude Code v2.1.218 将 Code Review 与 Forked Skill 默认移入后台执行，并要求 Agent Frontmatter Hook 的所属目录通过 Workspace Trust。该版本同时把更多危险或静态分析无法判定的命令交给 Auto-mode Classifier，使后台化、信任作用域和自动授权成为同一运行时中的关键边界。

[查看洞察](#) · [阅读原文](#)

Codex 用待处理 Mailbox 消息确定性唤醒持久睡眠线程

Codex 合并 PR 34852，把 Pending Agent Mail 设为 Durable Sleep Thread 的确定性唤醒条件，并保留普通空闲线程必须显式 trigger_turn 的约束。该修复消除了“消息已经持久化但睡眠线程永不恢复”的静默停滞，使 Mailbox 投递、线程恢复和后续处理共享可测试的状态语义。

[查看洞察](#) · [阅读原文](#)

kagent 将 A2A 只读权限下沉到 JSON-RPC 方法级门禁

kagent 将 A2A (Agent-to-Agent) 共享的只读控制从 HTTP 动词判断下沉到 JSON-RPC 方法级门禁，使任务读取和订阅能够通过，同时在处理器层拒绝发送消息、取消任务和写入 Push 配置。该版本还移除会破坏 OpenAI 流式 Responses 的重复遥测插桩，说明协议授权与可观测组件都必须以“不改变运行语义”为基本验收条件。

[查看洞察](#) · [阅读原文](#)

OpenSRE 用共享 setup flow 消除运维连接器凭据漂移

OpenSRE 将 PagerDuty、incident.io、Jenkins、Sentry、Datadog、数据库等运维连接器迁移到统一声明式 setup flow，以校验后持久化和跨 store、keyring、env 的一致写入消除配置入口漂移。相邻版本又为组织级凭据和 Slack 附件建立有界输入、秘密清理与敏感键强制分流，使 SRE Agent 的连接控制面同时覆盖配置正确性与上下文污染风险。

[查看洞察](#) · [阅读原文](#)

gh-aw 用静态规则与运行健康分类收紧 Agentic Workflow 失败语义

GitHub Agentic Workflows v0.83.0 用静态规则识别被零退出掩盖的失败和缺少异常处理的同步 I/O，并以 Action pin 守卫、Commit SHA 固定和重试隔离收紧工作流运行边界。运行健康指标开始区分零轮 driver exit 与 Agent 逻辑失败，OTLP（开放遥测协议）也在缺少结论信号时把非零 CLI 退出记为失败，使失败分类更接近真实执行阶段。

[查看洞察](#) · [阅读原文](#)

Cursor 用请求级分类与生产反馈在模型质量和成本之间动态路由

原始标题: [Introducing Cursor Router](#) · Article

Cursor · Cursor Team · 2026-07-22

Cursor 发布 Cursor Router，在每次请求执行前按 Query、Context、Task Complexity 与 Domain 分类，并在团队允许的模型池中选择执行模型。该机制把 Coding Agent 的模型选择从会话级人工偏好转为可在线评估的请求级控制面，使质量、缓存成本和组织策略能够在同一次路由决策中权衡。

变化与技术机制

Router 的分类器使用 60 万条以上真实请求训练，并在数百万请求的在线 A/B Test 中评估。执行链先由团队策略限定允许模型，再由分类器结合用户输入、上下文、任务复杂度、领域和模型行为选择执行者，随后运行模型，最后以满意度、代码 Keep Rate 与包含 Cache Miss 的成本评估结果。简单工作因此可以进入更具价格效率的模型，复杂长程任务则进入 Frontier Reasoning Model。

产品提供 Intelligence、Balance、Cost 三种优化模式，团队管理员可以设置可选模式、默认值并允许或阻止具体模型。在线质量信号包括从用户后续行为推断的满意度，以及 Agent 生成代码在代码库中的 Keep Rate；管理员因此获得成本—质量 Pareto Frontier（帕累托前沿）上的显式选择，而不是依赖单一全局模型。

关键解读

● 路由器需要按端到端结果而非单次推理价格评估

模型切换会改变缓存命中、后续纠错和整个会话的成本，只比较 Token 单价会低估路由开销。把用户纠错、代码留存和 Cache Miss 纳入生产评估，更接近 Agent 任务的真实经济性，但仍需要用测试通过率、返工与缺陷数据补充。

● 组织策略必须先于分类器缩小可选模型集合

团队级 Allow/Block Control（允许/阻止控制）让合规、数据边界或采购约束先限定模型池，再由分类器优化请求。路由策略还应记录版本、候选模型、选择理由和回退路径，否则模型更新会造成难以解释的质量或成本漂移。

技术图示



请求先经过策略约束与分类，再进入模型执行；生产反馈回到路由评估。 · [图示来源](#)

证据与限制

官方文章确认产品已向 Teams 与 Enterprise 发布，并披露训练规模、路由输入和评估指标；30%-60% 成本节省、满意度提升与 Cost per Commit 均来自 Cursor 自有流量，未公开完整样本、方差或第三方复现。

领域启示

可借鉴。 将模型路由实现为“策略过滤—任务分类—执行—结果反馈”的闭环，并同时记录质量、缓存和返工成本。

适用条件。 适合任务类型多样、模型池持续变化且具有足够真实反馈量的团队，前提是能够统一采集任务结果与后续纠错信号。

不宜照搬。 小样本团队不应直接训练高维分类器，也不能把用户满意度或代码 Keep Rate 单独当作正确性；高风险任务仍需确定性模型白名单和人工门禁。

来源

[阅读原文](#) · [佐证: Cursor Router](#) · [返回洞察速览](#)

Claude Code 用后台执行与目录级信任重划评审和工具授权边界

原始标题: [v2.1.218](#) · Release

Anthropic · Anthropic · 2026-07-22

Claude Code v2.1.218 将 Code Review 与 Forked Skill 默认移入后台执行，并要求 Agent Frontmatter Hook 的所属目录通过 Workspace Trust。该版本同时把更多危险或静态分析无法判定的命令交给 Auto-mode Classifier，使后台化、信任作用域和自动授权成为同一运行时中的关键边界。

变化与技术机制

这一 Release 的技术主线是让长评审与 Forked Context 不再占用主对话，同时为后台能力补上更明确的来源和终止控制。

/code-review 改为后台 Subagent，评审内容不再填满主会话；带 context: fork 的 Skill 默认后台运行，并可用 background: false 明确关闭。

来自不可信目录的 Agent Frontmatter Hook 必须先获得该目录的 Workspace Trust，Trust Dialog 会显示授权覆盖的 Repository Root。

Auto Mode 的 Dangerous-rm、后台 & 与可疑 Windows Path 检查，以及 Plan Mode 中静态分析器无法证明只读的 Bash 命令，改由 Auto-mode Classifier 裁决；同版还修复 Engine Teardown 可能产生 Phantom Turn 与远程 Worker 被替换后仍持续 Heartbeat 的问题。

关键解读

● 默认后台化要求结果、取消和上下文占用分别可见

把评审与 Skill 从主对话移出可以减少上下文竞争，但不能让执行状态变得不可见。Harness 需要分别呈现后台任务使用的上下文、当前进度、取消结果与最终产物，并保证主会话结束或 Worker 替换后不会留下 Phantom Turn 或失控重试。

● 自动分类不能削弱目录信任的确定性下限

目录级 Workspace Trust 约束 Hook 来源，Auto-mode Classifier 则决定更多具体命令能否执行，两者处于不同层级。来源未受信任时应先拒绝加载；来源已受信任后，分类器仍需对不确定命令失败关闭、提供可审计理由并允许组织策略设置不可绕过的硬规则。

证据与限制

官方稳定 Release 已包含上述默认行为与修复，但未披露 Auto-mode Classifier 的误判率、超时回退、企业锁定方式，也未给出后台 Review/Skill 对上下文成本、取消清理和任务质量的独立评测。

领域启示

可借鉴。 将后台任务的来源信任、执行生命周期和命令授权分层建模：先验证任务定义的目录，再跟踪后台状态，最后对具体 Tool Call 裁决。

适用条件。 适合评审或 Skill 会显著占用主会话、且项目包含多级 Agent 配置目录的团队，前提是有统一任务状态与目录信任存储。

不宜照搬。 不能因为操作来自自己信任仓库就跳过命令级检查，也不应让概率分类器替代所有确定性危险命令拒绝规则。

来源

[阅读原文](#) · [返回洞察速览](#)

Codex 用待处理 Mailbox 消息确定性唤醒持久睡眠线程

原始标题: [Wake sleeping threads for queued agent mail](#) · PR

OpenAI · OpenAI Codex maintainers · 2026-07-23

Codex 合并 PR 34852，把 Pending Agent Mail 设为 Durable Sleep Thread 的确定性唤醒条件，并保留普通空闲线程必须显式 trigger_turn 的约束。该修复消除了“消息已经持久化但睡眠线程永不恢复”的静默停滞，使 Mailbox 投递、线程恢复和后续处理共享可测试的状态语义。

变化与技术机制

失效发生在 Queue-only Agent Mail：发送方只把消息排入目标线程 Mailbox，不触发新 Turn；若目标 Root Thread 正处于 Durable Sleep，原调度器不会把这条消息视为待处理工作，因此线程持续休眠。消息本身已经保存，外部观察却可能误以为任务仍会自然推进。

修复后的流程先把 Queue-only Mail 持久化为 Pending Mailbox Message，再检查目标 Thread 的等待状态，随后只唤醒具有 Durable Sleep 的空闲线程，最后由恢复后的线程处理消息；没有 Durable Sleep 的普通空闲线程仍需显式 trigger_turn。回归测试覆盖睡眠 Root Thread 被唤醒且消息继续保留，从而同时验证唤醒条件与持久化结果。

关键解读

● 持久消息必须参与可恢复执行的调度判定

将消息写入存储只保证“不会丢”，不能保证“会被处理”。调度器必须把未消费消息纳入可唤醒工作集合，并让唤醒、消费确认和再次休眠形成明确状态机，否则异步协作会出现无错误日志的永久停滞。

● 唤醒范围需要由等待状态而非“收到消息”单独决定

所有空闲线程收到消息都立即运行，会破坏显式触发与批处理语义；永不自动唤醒又会让 Durable Sleep 失去恢复价值。按等待状态区分持久睡眠与普通空闲，可以让 Queue-only Mail 只恢复已声明可被事件唤醒的线程。

技术图示



Queue-only Mail 先持久化，再由 Durable Sleep 判定唤醒；普通空闲线程仍等待显式触发。 · [图示来源](#)

证据与限制

官方已合并 PR 提供了具体失效链、修复和回归测试，可以确认主分支行为；该修复尚未在本轮已读稳定 Release 中出现，多消息竞态、重复投递、崩溃恢复和非 Root Thread 语义仍未公开完整验证。

领域启示

可借鉴。为异步 Agent 设计显式等待状态，并把未消费 Mailbox 消息纳入可恢复调度器的工作判定与回归测试。

适用条件。适合具有持久线程、事件队列和长时间等待的多 Agent Harness，前提是消息有稳定 ID、消费状态和幂等处理边界。

不宜照搬。不应让任意通知都唤醒所有空闲线程；高频消息、重复投递和不可幂等 Tool Call 需要合并、去重和背压控制。

来源

[阅读原文](#) · [返回洞察速览](#)

kagent 将 A2A 只读权限下沉到 JSON-RPC 方法级门禁

原始标题: [v0.10.0-beta10](#) · Release

CNCF kagent · kagent 维护者 · 2026-07-22

kagent 将 A2A (Agent-to-Agent) 共享的只读控制从 HTTP 动词判断下沉到 JSON-RPC 方法级门禁, 使任务读取和订阅能够通过, 同时在处理器层拒绝发送消息、取消任务和写入 Push 配置。该版本还移除会破坏 OpenAI 流式 Responses 的重复遥测插桩, 说明协议授权与可观测组件都必须以“不改变运行语义”为基本验收条件。

变化与技术机制

A2A 使用 JSON-RPC over POST, 旧中间件却把“只读”解释为只允许 GET, 导致默认只读 share token 无法调用 ListTasks 或 GetTask。beta10 允许 A2A 请求进入处理器, 再由 requireWritableShare 对 SendMessage、CancelTask、创建或删除 Push 配置等变更方法失败关闭; 读取任务、读取或列出 Push 配置及订阅则保持可用, 同一处理器同时覆盖 A2A v0 与 v1。

运行时的另一项修复针对 OpenTelemetry (开放遥测) 插桩。kagent 同时安装低层 OpenAI SDK 插桩与 OpenAI Agents 专用插桩时, 低层组件无法处理流式 AsyncStream, 会让任务以属性错误终止; 新版只在追踪或日志启用时安装观测组件, 并让 Agents 专用插桩单独负责 OpenAI 路径, 同时固定相关依赖版本上界。

关键解读


● RPC 权限必须绑定操作能力而不是传输动词

HTTP POST 在 JSON-RPC 中只是统一信封, 既可承载读取也可承载写入。把权限放在方法处理器可以区分任务查询、订阅、消息发送与取消, 但前提是新方法默认失败关闭, 并有自动化测试保证 v0/v1 方法清单不会漂移。

● 遥测开关必须真正隔离运行行为

观测库会 patch SDK、流式对象和重试链, 因此不是天然无副作用的旁路。关闭遥测时不应安装插桩, 启用时也要覆盖流式、工具调用、取消和异常路径; 否则“增加可观测性”本身可能成为任务失败源。

技术图示



A2A 请求先按 JSON-RPC 方法分类；读取路径继续执行，变更路径由只读共享门禁拒绝。 · [图示来源](#)

证据与限制

官方 Release 和已合并 PR 能确认旧权限判断的根因、读写方法清单及重复插桩导致的流式崩溃；beta10 仍处版本早期阶段，尚未披露跨租户数据边界、完整方法覆盖、真实性能开销或生产集群验证。

领域启示

- 可借鉴。为基于 RPC、GraphQL 或统一 POST 入口的 Agent 工具建立逐方法 capability matrix（能力矩阵），并把遥测启停的行为等价性纳入回归测试。
- 适用条件。适合提供共享会话、任务订阅或跨 Agent 调用，且同时支持只读令牌和可写令牌的 Kubernetes Agent 平台。
- 不宜照搬。不能只复制当前方法 allowlist；还需结合租户、会话、字段级返回、回调目的地和新版本方法的默认拒绝策略，并验证插桩在所用 SDK 版本上的兼容性。

来源

[阅读原文](#) · [佐证: Allow read-only shares to read A2A tasks](#) · [佐证: Don't double-instrument OpenAI on the agents runtime](#) · [返回洞察速览](#)

OpenSRE 用共享 setup flow 消除运维连接器凭据漂移

原始标题: [OpenSRE 0.1.2026.7.23](#) · Release

Tracer Cloud / OpenSRE · OpenSRE 维护者 · 2026-07-23

OpenSRE 将 PagerDuty、incident.io、Jenkins、Sentry、Datadog、数据库等运维连接器迁移到统一声明式 setup flow，以校验后持久化和跨 store、keyring、env 的一致写入消除配置入口漂移。相邻版本又为组织级凭据和 Slack 附件建立有界输入、秘密清理与敏感键强制分流，使 SRE Agent 的连接器控制面同时覆盖配置正确性与上下文污染风险。

变化与技术机制

OpenSRE 过去有 onboarding wizard、integrations setup 和 action tool 等多个配置入口，各自能触达的存储层不同。关联 PR 披露，PagerDuty 等入口曾只把凭据写入内部 store，而部署前检查读取 env，导致本地校验成功、部署时却报告缺少凭据；共享 setup flow 现在统一字段定义、在线 verifier、verify-before-persist 和三层往返，失败验证不向任何层落盘，敏感键与非敏感键也由公共写入器强制分流。

前一日 Release 同时把组织级 Webapp integration vault 接入 gateway，并为 Slack 文件附件建立输入预算。日志、CSV、JSON 和 YAML 采用流式下载、单文件与总字符上限并清理明显秘密；图片只做一次视觉描述后转为文本上下文，不把多模态对象直接带入 ReAct 循环。

关键解读

● 配置入口必须共享同一个验证与持久化事务

同一连接器若在 wizard、CLI 和 Agent action 中拥有不同写入逻辑，局部成功并不能保证部署环境可解析。更稳健的设计是把字段、校验、敏感性分类和持久化放在可复用底层，并对“验证失败零落盘”和“写后读回一致”建立参数化测试。

● 上下文入口也需要像凭据入口一样做预算与净化

附件会把日志、令牌和大型文件直接带入模型上下文，既增加秘密暴露面，也可能挤占调查所需证据。流式大小限制、总字符预算、秘密清理和图片文本化能缩小风险，但仍需要覆盖编码变体、压缩文件、间接凭据和误删运维标识等边界。

证据与限制

官方 Release 和合并 PR 能确认旧入口漂移的具体根因、统一 setup flow、失败验证不落盘及参数化测试结果；OpenSRE 仍为 Public Alpha，附件秘密清理仅覆盖明显模式，连接器迁移尚未覆盖所有分支配置与 either/or 字段，也没有独立生产可靠性证据。

领域启示

可借鉴。把每个连接器建模为“字段规范—在线校验—敏感性分类—原子持久化—跨入口往返测试”，并为送入 Agent 的文件建立下载、净化和上下文预算层。

适用条件。适合同时提供 Web、CLI、ChatOps 和 Agent action 配置入口，且部署阶段会从多种 secret store 与环境变量解析连接器的 SRE 平台。

不宜照搬。不能把基于变量名的敏感性分类当作完整数据防泄漏方案；复杂连接器仍需处理条件字段、集合类型、撤销、轮换、并发更新和跨租户授权。

来源

[阅读原文](#) · [佐证: OpenSRE 0.1.2026.7.22](#) · [佐证: Move env/keyring writing to a shared config layer](#) · [佐证: Migrate incident.io, Jenkins and PagerDuty onto the shared setup flow](#) · [返回洞察速览](#)

gh-aw 用静态规则与运行健康分类收紧 Agentic Workflow 失败语义

原始标题: [v0.83.0](#) · Release

GitHub / github/gh-aw · GitHub Agentic Workflows 维护者 · 2026-07-22

GitHub Agentic Workflows v0.83.0 用静态规则识别被零退出掩盖的失败和缺少异常处理的同步 I/O，并以 Action pin 守卫、Commit SHA 固定和重试隔离收紧工作流运行边界。运行健康指标开始区分零轮 driver exit 与 Agent 逻辑失败，OTLP（开放遥测协议）也在缺少结论信号时把非零 CLI 退出记为失败，使失败分类更接近真实执行阶段。

变化与技术机制

这次 Pre-release 的技术主线是让“失败”在生成、执行和观测三个层面保持一致。编译与 lint 阶段增加规则，检查 setFailed 后仍以零状态退出、execFileSync 和文件同步 I/O 未捕获异常等模式；运行时拒绝空的 Action pin SHA，并将 Docker build action 固定到 Commit SHA，降低生成配置或依赖引用漂移进入执行阶段的概率。

在故障路径上，Anthropic SDK 内层重试被关闭，避免 API 不可靠时与外层工作流重试叠加成终端错误风暴。健康指标将 Agent 尚未开始任何轮次便退出的 driver-exit 与 Agent 推理或工具执行失败分开；当结论与错误信号都缺失时，OTLP 仍依据 Copilot CLI 的非零退出补记失败。

关键解读

● 失败语义需要贯穿源码、运行时与遥测

单一层面的红色状态并不足以解释 Agent 工作流为什么失败。静态规则用于阻止明显的失败掩盖，运行时守卫阻止无效配置，健康分类则区分驱动未启动和 Agent 逻辑错误；三层使用一致语义后，告警、重试和责任定位才有稳定依据。

● 嵌套重试会把外部不可靠放大为内部错误风暴

SDK、Agent runtime 和流水线若各自独立重试，同一次上游抖动可能被乘法放大，并掩盖最初错误。重试所有权应集中在能够看到预算、幂等性和整体 deadline（截止时间）的层级，内层组件则向上返回结构化失败。

证据与限制

官方 Pre-release 可确认静态规则、Action 固定、重试控制和健康分类已经进入 v0.83.0；现有材料没有给出规则误报率、历史失败重分类结果、生产工作流效果或稳定版时间，Sighthound/CodeQL 修复也不能推导为整体供应链已安全。

领域启示

可借鉴。 为 Agentic CI 建立统一 failure taxonomy（失败分类），把生成时 lint、运行时退出、重试预算和遥测结论映射到同一阶段模型。

适用条件。 适合使用多层 SDK、外部模型 API、生成式 workflow 配置和集中 OTLP 指标，并需要区分平台故障与 Agent 行为故障的团队。

不宜照搬。 不应直接复制规则或重试禁用配置；需要结合语言运行时、幂等性、Action 供应链、外部 API SLA 和现有告警语义验证误报、漏报与恢复行为。

来源

[阅读原文](#) · [返回洞察速览](#)

今日可采取动作

以下行动全部由本日精选洞察直接推导；如需投入环境或权限，请先按适用前提进行小范围验证。

可立即核查

核对模型路由是否留下可追溯决策记录

动作：只读检查现有 Coding Agent 的模型选择日志是否同时记录候选模型、组织策略、实际选择、缓存命中与任务结果。

预期确认的问题：当前系统能否解释一次路由为何发生，以及模型更新后质量或成本漂移从何而来。

[查看关联洞察：Cursor 用请求级分类与生产反馈在模型质量和成本之间动态路由](#)

核查 RPC 权限是否错误绑定 HTTP 动词

动作：只读检查现有 Agent 工具网关的 REST、JSON-RPC、GraphQL 与流式入口，列出每个 token 类型可调用的方法，并标记仍只按 GET/POST 判断读写权限的路径。

预期确认的问题：当前权限模型是否会误封读取方法，或因放宽统一 POST 入口而同时放开变更方法。

[查看关联洞察：kagent 将 A2A 只读权限下沉到 JSON-RPC 方法级门禁](#)

适合进入试点

为持久睡眠线程建立消息唤醒回归矩阵

试点建议：在隔离测试环境覆盖 Queue-only Mail、重复消息、崩溃恢复和普通空闲线程四类场景，验证唤醒次数、消息保留与 Tool 副作用。

适用前提：Harness 已有持久 Thread ID、Mailbox ID、可控时钟和幂等测试 Tool。

验证指标：漏唤醒数、重复唤醒数、消息重复处理数、恢复时延和副作用重复率。

[查看关联洞察：Codex 用待处理 Mailbox 消息确定性唤醒持久睡眠线程](#)

为一个运维连接器建立跨入口往返测试

试点建议：选择一个低风险、只读连接器，让 Web、CLI 与 Agent action 共用字段规范和 verifier，并验证成功后各存储层可读、失败时所有层零落盘。

适用前提：具备隔离测试账号、临时凭据、可清理 secret store 和不触发生产副作用的在线校验接口。

验证指标：跨入口配置一致率、失败残留凭据数、部署前缺失凭据误报数、敏感键误分类数和回滚时间。

[查看关联洞察：OpensRE 用共享 setup flow 消除运维连接器凭据漂移](#)

继续观察

观察 Auto-mode Classifier 是否保持失败关闭

观察对象：Claude Code 对危险命令与 Plan Mode 不确定 Bash 的分类器裁决。

当前证据缺口：官方未披露分类规则、误判率、超时回退和组织级不可绕过策略。

重新评估条件：公开安全说明、独立对抗测试或企业策略文档能够确认分类失败时的拒绝语义。

[查看关联洞察：Claude Code 用后台执行与目录级信任重划评审和工具授权边界](#)

跟踪 gh-aw 失败分类进入稳定版后的效果

观察对象：v0.83.0 的失败掩盖规则、driver-exit 分类、OTLP fallback 和 SDK 重试控制。

当前证据缺口：缺少规则误报率、历史失败重分类、生产告警变化、稳定版验证和重试风暴改善数据。

重新评估条件：相关机制进入 Latest Release，并公开回归样本、故障分布或真实工作流运行数据。

[查看关联洞察：gh-aw 用静态规则与运行健康分类收紧 Agentic Workflow 失败语义](#)